



UNIVERSIDAD DE BUENOS AIRES

Departamento de Computación

Facultad de Ciencias Exactas y Naturales

Bases de Datos

Trabajo Práctico 2

10 de noviembre de 2015

Integrante	LU	Correo electrónico
Maurizio, Miguel Sebastián	635/11	miguelmaurizio.92@gmail.com
Prillo, Sebastián	616/11	sebastianprillo@gmail.com
Tagliavini Ponce, Guido	783/11	guido.tag@gmail.com

Índice

1. Introducción	1
2. Ejercicio 1	1
2.1. Desnormalización	1
2.1.1. Documento empleados	1
2.1.2. Documento articulos	2
2.1.3. Documento sectores	2
2.1.4. Documento clientes	3
2.2. Consultas	4
2.2.1. Los empleados que atendieron clientes mayores de edad	4
2.2.2. Los artículos más vendidos	4
2.2.3. Los sectores donde trabajan exactamente 3 empleados	4
2.2.4. El empleado que trabaja en más sectores	5
2.2.5. Ranking de los clientes con mayor cantidad de compras	5
2.2.6. Cantidad de compras realizadas por clientes de misma edad	5
3. Ejercicio 2	6
3.1. Consultas	6
3.1.1. Cantidad de disposiciones tipo <i>resoluciones</i> que se hayan realizado en Abril de 2013	6
3.1.2. Cantidad de disposiciones por cada tipo definido	6
3.1.3. Fecha más citada para todos los informes	7
3.1.4. Máxima cantidad de páginas utilizadas por cada tipo de disposición	7
4. Ejercicio 3	8
4.1. Características de un buen atributo para sharding	8
4.2. Ejemplos de sharding	8
5. Ejercicio 4	8
5.1. Consultas	9
5.1.1. Los empleados que atendieron clientes mayores de edad	9
5.1.2. Los artículos más vendidos	9
5.1.3. Los sectores donde trabajan exactamente 3 empleados	9
5.1.4. El empleado que trabaja en más sectores	9
5.1.5. Ranking de los clientes con mayor cantidad de compras	9
5.1.6. Cantidad de compras realizadas por clientes de misma edad	10
5.2. Sharding	10
6. Conclusión	10

1. Introducción

2. Ejercicio 1

En este ejercicio diseñamos una base de datos NoSQL de tipo documentos con la capacidad de responder rápidamente a varias consultas. Para ello, empleamos desnormalización, diseñando documentos adecuados para las consultas.

2.1. Desnormalización

Desnormalizamos el esquema, de la forma tradicional. Cada entidad tiene un documento asociado. Las relaciones 1:N se incluyen en el documento asociado al lado 1. Las relaciones N:M se incluyen a ambos lados de la relación.

2.1.1. Documento empleados

```
empleados {
  nro_legajo : INTEGER
  nombre : STRING
  clientes_atendidos : [{dni : STRING, edad : INTEGER, fecha : DATETIME}]
  sectores_donde_trabaja : [{cod_sector : INTEGER, id_tarea : INTEGER}]
}
```

Observar que en `clientes_atendidos` nos guardamos, además del atributo identificador `dni` y el atributo de relación `fecha`, la `edad` de los clientes atendidos. Este atributo será necesario para responder una de las consultas, posteriormente.

Insertamos algunos documentos:

```
db.empleados.insert({
  nro_legajo : 1,
  nombre : "empleado1",
  clientes_atendidos : [ {dni : "11111111", edad : 18, fecha : "01/01/2015"},
                        {dni : "22222222", edad : 17, fecha : "01/02/2015"} ],
  sectores_donde_trabaja : [{cod_sector : 1, id_tarea : 1} , {cod_sector : 2, cod_tarea : 1}]
})
```

```
db.empleados.insert({
  nro_legajo : 2,
  nombre : "empleado2",
  clientes_atendidos : [ {dni : "22222222", edad : 17, fecha : "02/02/2015"} ],
  sectores_donde_trabaja : [{cod_sector : 1, id_tarea : 1}, {cod_sector : 2, cod_tarea : 1}]
})
```

```
db.empleados.insert({
  nro_legajo : 3,
  nombre : "empleado3",
  clientes_atendidos : [{dni : "33333333", edad : 19, fecha : "01/03/2015"}],
  sectores_donde_trabaja : [{cod_sector : 1, id_tarea : 1}, {cod_sector : 2, cod_tarea : 1}]
})
```

```

db.empleados.insert({
  nro_legajo : 4,
  nombre : "empleado4",
  clientes_atendidos : [],
  sectores_donde_trabaja : [{cod_sector : 1, id_tarea : 1}]
})

```

2.1.2. Documento articulos

```

articulos {
  codigo : STRING
  nombre : STRING
  ventas : [{dni : STRING}]
}

```

Insertamos algunos documentos:

```

db.articulos.insert({
  codigo : "1",
  nombre : "articulo1",
  ventas : [{dni : "11111111"}, {dni : "22222222"}]
})

```

```

db.articulos.insert({
  codigo : "2",
  nombre : "articulo2",
  ventas : [{dni : "11111111"}, {dni : "33333333"}]
})

```

```

db.articulos.insert({
  codigo : "3",
  nombre : "articulo3",
  ventas : [{dni : "33333333"}]
})

```

2.1.3. Documento sectores

```

sectores{
  cod_sector : INTEGER
  articulos : [{codigo : STRING}]
  trabaja : [{nro_legajo : INTEGER, id_tarea : INTEGER}]
}

```

Insertamos algunos documentos:

```

db.sectores.insert({
  cod_sector : 1,
  articulos : [{codigo : "1"}],
  trabaja : [ {nro_legajo : 1, id_tarea : 1},
               {nro_legajo : 2, id_tarea : 1},

```

```

        {nro_legajo : 3, id_tarea : 1},
        {nro_legajo : 4, id_tarea : 1}]
    })

db.sectores.insert({
    cod_sector : 2,
    articulos : [{codigo : "2"}],
    trabaja : [ {nro_legajo : 1, id_tarea : 1},
                {nro_legajo : 2, id_tarea : 1},
                {nro_legajo : 3, id_tarea : 1}]
    })

```

2.1.4. Documento clientes

```

clientes{
    dni : STRING
    nombre : STRING,
    edad : INTEGER,
    atendido_por : [{nro_legajo : INTEGER, fecha : DATETIME}],
    compro_articulos : [{codigo : INTEGER}]
}

```

Insertamos algunos documentos:

```

db.clientes.insert({
    dni : "11111111",
    nombre : "cliente1",
    edad : 18,
    atendido_por : [{nro_legajo : 1, fecha : "01/01/2015"}],
    compro_articulos : [{codigo : "1"} , {codigo : "2"}]
    })

db.clientes.insert({
    dni : "22222222",
    nombre : "cliente2",
    edad : 17,
    atendido_por : [{nro_legajo : 1, fecha : "01/02/2015"} , {nro_legajo : 2,
                                                                fecha : "02/02/2015"}],
    compro_articulos : [{codigo : "1"}]
    })

db.clientes.insert({
    dni : "33333333",
    nombre : "cliente3",
    edad : 19,
    atendido_por : [{nro_legajo : 1, fecha : "01/03/2015"}],
    compro_articulos : [{codigo : "2"} , {codigo : "3"}]
    })

```

2.2. Consultas

2.2.1. Los empleados que atendieron clientes mayores de edad

```
db.empleados.find(
  {"clientes_atendidos.edad" : {$gte : 18}},
  {"nro_legajo" : 1, nombre : 1}
)
```

Equivalenemente, podríamos pedir:

```
db.empleados.find(
  {"clientes_atendidos" : {$elemMatch : {"edad" : {$gte : 18}}}},
  {"nro_legajo" : 1, nombre : 1}
)
```

La query nos retorna, como deseamos:

```
{ "_id" : ObjectId("56420cfd92d300ad159887da"), "nro_legajo" : 1, "nombre" : "empleado1" }
{ "_id" : ObjectId("56420cfd92d300ad159887dc"), "nro_legajo" : 3, "nombre" : "empleado3" }
```

2.2.2. Los artículos más vendidos

```
db.articulos.aggregate([
  {$project : {"cant_ventas" : {$size : "$ventas"} , nombre : 1, codigo : 1}},
  {$sort : {"cant_ventas" : -1}},
])
```

La respuesta a esta consulta es:

```
{ "_id" : ObjectId("56420d1e92d300ad159887de"), "codigo" : "1", "nombre" : "articulo1",
  "cant_ventas" : 2 }
{ "_id" : ObjectId("56420d1e92d300ad159887df"), "codigo" : "2", "nombre" : "articulo2",
  "cant_ventas" : 2 }
{ "_id" : ObjectId("56420d1e92d300ad159887e0"), "codigo" : "3", "nombre" : "articulo3",
  "cant_ventas" : 1 }
```

Así, vemos que los articulos mas vendidos son los de codigo 1 y 2, cada uno con 2 ventas.

2.2.3. Los sectores donde trabajan exactamente 3 empleados

```
db.sectores.find(
  {"trabaja" : {$size : 3}},
  {"cod_sector" : 1}
)
```

La respuesta a esta consulta es:

```
{ "_id" : ObjectId("56420d9e92d300ad159887e2"), "cod_sector" : 2 }
```

Efectivamente, el sector 2 contiene exactamente 3 trabajadores.

2.2.4. El empleado que trabaja en más sectores

```
db.empleados.aggregate([
  {$project : {cant_sectores : {$size : "$sectores_donde_trabaja"} , nombre : 1, nro_legajo : 1},
  {$sort : {cant_sectores : -1}},
  {$limit : 1}
])
```

La respuesta a esta consulta es:

```
{ "_id" : ObjectId("56420cfd92d300ad159887da"), "nro_legajo" : 1, "nombre" : "empleado1",
  "cant_sectores" : 2 }
```

Si bien los empleados 2 y 3 también trabajan en dos sectores, solo se nos pide dar uno solo, así que desempataremos arbitrariamente.

2.2.5. Ranking de los clientes con mayor cantidad de compras

```
db.clientes.aggregate([
  {$project : {cant_compras : {$size : "$compro_articulos"} , nombre : 1, dni : 1}},
  {$sort : {cant_compras : -1}}
])
```

La respuesta a esta consulta es:

```
{ "_id" : ObjectId("56420df292d300ad159887e3"), "dni" : "11111111", "nombre" : "cliente1",
  "cant_compras" : 2 }
{ "_id" : ObjectId("56420df392d300ad159887e5"), "dni" : "33333333", "nombre" : "cliente3",
  "cant_compras" : 2 }
{ "_id" : ObjectId("56420df292d300ad159887e4"), "dni" : "22222222", "nombre" : "cliente2",
  "cant_compras" : 1 }
```

Como vemos, los clientes aparecen ordenados de mayor a menor cantidad de compras.

2.2.6. Cantidad de compras realizadas por clientes de misma edad

```
db.clientes.aggregate([
  {$project : {cant_compras : {$size : "$compro_articulos"} , nombre : 1, dni : 1, edad : 1}},
  {$group : {
    _id : "$edad",
    total_compras : {$sum : "$cant_compras"}
  }}
])
```

El resultado de la query es:

```
{ "_id" : 19, "total_compras" : 2 }
{ "_id" : 17, "total_compras" : 1 }
{ "_id" : 18, "total_compras" : 2 }
```

En definitiva, este es un diseño de documentos que, mediante documentos adecuados y redundancia, permite responder rápidamente a todas las queries pedidas.

3. Ejercicio 2

3.1. Consultas

3.1.1. Cantidad de disposiciones tipo *resoluciones* que se hayan realizado en Abril de 2013

```
var map1 = function(){
    emit(this["Tipo"],1)
}

var reduce1 = function(key,values){
    return Array.sum(values)
}

db.disposiciones.mapReduce(map1,reduce1,{query : {FechaDisposicion : {$regex : /^2013-04-/},
    Tipo : "Resoluciones"}, out : "map_res"})
db.map_res.find()
```

El resultado de esta consulta es:

```
{ "_id" : "Resoluciones", "value" : 642 }
```

3.1.2. Cantidad de disposiciones por cada tipo definido

```
var map2 = function(){
    emit(this["Tipo"],1)
}

var reduce2 = function(key,values){
    return Array.sum(values)
}

db.disposiciones.mapReduce(map2,reduce2,{query : {}, out : "map_res"})
db.map_res.find()
```

El resultado de esta consulta es:

```
{ "_id" : "", "value" : 3 }
{ "_id" : "Acuerdos", "value" : 2790 }
{ "_id" : "Acuerdos del Consejo de Gobierno", "value" : 160 }
{ "_id" : "Anuncios", "value" : 17226 }
{ "_id" : "Candidaturas", "value" : 1 }
{ "_id" : "Certificaciones", "value" : 72 }
{ "_id" : "Circular", "value" : 1 }
{ "_id" : "Conflictos Positivos", "value" : 6 }
{ "_id" : "Correcciones de Erratas", "value" : 59 }
{ "_id" : "Correcciones de Errores", "value" : 321 }
{ "_id" : "Correcciones de erratas", "value" : 8 }
{ "_id" : "Correcciones de errores", "value" : 44 }
{ "_id" : "Corrección de errores", "value" : 1 }
{ "_id" : "Corrección de errores", "value" : 1 }
```



```

{ "_id" : "Cuestiones de Inconstitucionalidad", "value" : 1 }
{ "_id" : "Decretos", "value" : 828 }
{ "_id" : "Decretos Legislativos", "value" : 5 }
{ "_id" : "Decretos del Presidente", "value" : 13 }
{ "_id" : "Decretos-leyes", "value" : 15 }
{ "_id" : "Edictos", "value" : 3223 }
{ "_id" : "Instrucciones", "value" : 2 }
{ "_id" : "Leyes", "value" : 12 }
{ "_id" : "Notificaciones", "value" : 768 }
{ "_id" : "Orden", "value" : 4 }
{ "_id" : "Otros", "value" : 45 }
{ "_id" : "Reales Decretos", "value" : 5 }
{ "_id" : "Recursos de Inconstitucionalidad", "value" : 7 }
{ "_id" : "Requisitorias", "value" : 2 }
{ "_id" : "Resoluciones", "value" : 13956 }
{ "_id" : "Órdenes", "value" : 2061 }
{ "_id" : "Órdenes de Comision Delegada", "value" : 2 }

```

3.1.3. Fecha más citada para todos los informes

```

var map3 = function(){
    emit(this["FechaBOJA"],1)
}

var reduce3 = function(key,values){
    return Array.sum(values)
}

db.disposiciones.mapReduce(map3,reduce3,{query : {}, out : "map_res"})
db.map_res.find().sort({value : -1}).limit(1)

```

El resultado de esta consulta es:

```

{ "_id" : "01/08/2012", "value" : 242 }

```

3.1.4. Máxima cantidad de páginas utilizadas por cada tipo de disposición

```

var map4 = function(){
    emit(this["Tipo"],this["PaginaFinal"] - this["PaginaInicial"] + 1)
}

var reduce4 = function(key,values){
    res = values[0]
    for (var i=1; i < values.length; i++){
        if(res < values[i]){
            res = values[i]
        }
    }
    return res
}

```

```
db.disposiciones.mapReduce(map4,reduce4,{query : {}, out : "map_res"})
db.map_res.find()
```

El resultado de esta consulta es:

```
{ "_id" : "", "value" : 16 }
{ "_id" : "Acuerdos", "value" : 12 }
{ "_id" : "Acuerdos del Consejo de Gobierno", "value" : 83 }
{ "_id" : "Anuncios", "value" : 393 }
{ "_id" : "Candidaturas", "value" : 68 }
{ "_id" : "Certificaciones", "value" : 47 }
{ "_id" : "Circular", "value" : 3 }
{ "_id" : "Conflictos Positivos", "value" : 1 }
{ "_id" : "Correcciones de Erratas", "value" : 174 }
{ "_id" : "Correcciones de Errores", "value" : 99 }
{ "_id" : "Correcciones de erratas", "value" : 10 }
{ "_id" : "Correcciones de errores", "value" : 5 }
{ "_id" : "Corrección de errores", "value" : 1 }
{ "_id" : "Corrección de errores", "value" : 1 }
{ "_id" : "Cuestiones de Inconstitucionalidad", "value" : 1 }
{ "_id" : "Decretos", "value" : 492 }
{ "_id" : "Decretos Legislativos", "value" : 37 }
{ "_id" : "Decretos del Presidente", "value" : 3 }
{ "_id" : "Decretos-leyes", "value" : 139 }
{ "_id" : "Edictos", "value" : 48 }
{ "_id" : "Instrucciones", "value" : 3 }
{ "_id" : "Leyes", "value" : 194 }
{ "_id" : "Notificaciones", "value" : 11 }
{ "_id" : "Orden", "value" : 7 }
{ "_id" : "Otros", "value" : 65 }
{ "_id" : "Reales Decretos", "value" : 1 }
{ "_id" : "Recursos de Inconstitucionalidad", "value" : 1 }
{ "_id" : "Requisitorias", "value" : 1 }
{ "_id" : "Resoluciones", "value" : 454 }
{ "_id" : "Órdenes", "value" : 634 }
{ "_id" : "Órdenes de Comision Delegada", "value" : 2 }
```

4. Ejercicio 3

4.1. Características de un buen atributo para sharding

Para que un atributo sea un buen candidato para aplicar la técnica de sharding, debe ser tal que al particionar los datos por ese atributo, las clases que se formen sean de tamaños similares. Esto permite que la carga sobre los shards esté bien distribuída, no sólo en términos del volumen de cada shard, sino también en el sentido de que los accesos y escrituras sean uniformes. Bajo estas condiciones obtendremos una mejor performance de I/O. Específicamente, la latencia y el tiempo de respuesta de los mismos serán bajos, gracias a que evitamos cuellos de botella.

Para ilustrar esto, pensemos en un mal ejemplo de sharding. Consideremos una base de datos que contenga los datos de los alumnos del Departamento de Computación de la facultad. Si hacemos sharding sobre el atributo

género, tendremos dos shards completamente asimétricos en su tamaño. Claramente, la enorme mayoría de los accesos serán sobre el shard de alumnos de sexo masculino, lo cual tiene un obvio impacto en la performance.

Vale la pena mencionar que el sharding puede ser de utilidad no sólo para asegurar balanceo de carga. En ciertos sistemas, son habituales las consultas que necesitan revisar únicamente un subconjunto de todo el universo de elementos. En estos casos, es útil hacer sharding de modo tal de que uno de estos subconjuntos que nos interesan estén separados en shards. Tomemos como ejemplo un base de datos de una red social, en la cual se hace sharding por el país de residencia de las personas. En este caso, podremos optimizar la consulta *amigos de una persona*, puesto que, en general, la mayor parte de los amigos de una persona están geográficamente cerca.

4.2. Ejemplos de sharding

Algunos ejemplos de una buena elección de un atributo para hacer sharding son los siguientes:

1. Sharding por atributo *género* en una base de datos del padrón electoral de un país.
2. Sharding por atributo *país de residencia* en una base de datos de personas de una red social.
3. Sharding por atributo *año de nacimiento* en una base de datos de personas nacidas durante cierto período de tiempo, fijo. Por ejemplo, durante la dictadura de 1976.

Se puede ver que en los tres casos, la proporción de los grupos en los que clasificamos es aproximadamente la misma, y que, a priori, no debería haber ninguna tendencia de acceso a un shard en particular.

Una alternativa siempre útil es hacer sharding utilizando hashing. Esto significa tomar un atributo cuya distribución sea más o menos uniforme (por ejemplo, un atributo identificador o un número de teléfono), y shardear utilizando el hasheo del atributo.

5. Ejercicio 4

Las bases de datos NoSQL del tipo *column family* almacenan la información, no por filas como las bases de datos SQL tradicionales, sino por columnas. Esto permite realizar queries que requieren acceder a grandes cantidades de datos eficientemente. Esta eficiencia se basa en dos hipótesis. La primera es que, en general, las consultas sólo requieren un subconjunto de la totalidad de las columnas de una tabla, con lo cual resulta conveniente poder restringirse sólo a las columnas necesarias. La segunda es que, cuando la cantidad de datos de la respuesta es grande, tendremos que leer casi todos los valores de una columna, por lo que resulta útil que estén almacenados consecutivamente.

Una base de datos de este tipo se compone de *familias de columnas*. Cada familia de columnas se compone de varias *claves de fila* (simbolizadas con K), y asociada a cada una de estas claves hay *columnas* (simbolizadas con C) con sus respectivos valores. Finalmente, asociado a cada clave de fila también suele almacenarse un timestamp, que es utilizado para determinar el tiempo de expiración de los datos.

Para diseñar bases de datos de este tipo, creamos, para cada query, una o más familias de columnas que sean capaces de responder a la consulta. Esto implica que los datos almacenados son estrictamente los requeridos para responder a las consultas.

5.1. Consultas

5.1.1. Los empleados que atendieron clientes mayores de edad

idRow	K
legajo_empleado_que_atendio_mayor	C ↑

En este caso, tenemos una clave de fila *dummy*, *idRow*, en la cual se almacenarán una secuencia de columnas *legajo_empleado_que_atendio_mayor*. Cada valor de una columna *legajo_empleado_que_atendio_mayor* es el identificador de un empleado que atendió a una persona mayor de edad.

La actualización de esta familia es sencilla. Cada vez que se realiza una venta, debemos verificar si el cliente es mayor de edad, en cuyo caso insertamos en la familia al empleado que lo atendió, siempre que no estuviera en la familia de antemano.

5.1.2. Los artículos más vendidos

<i>codigo_articulo</i>	K
<i>cantidad_vendida</i>	++

A cada artículo le asociamos un contador *cantidad_vendida*. Con esta información es fácil extraer aquellos artículos cuyo valor del contador sea máximo.

La actualización consiste en incrementar el contador de un artículo, cada vez que es vendido.

5.1.3. Los sectores donde trabajan exactamente 3 empleados

<i>codigo_sector</i>	K
<i>legajo_empleado_del_sector</i>	C ↑

Para cada sector, almacenamos todos los empleados que trabajan allí. Determinar aquellos sectores donde trabajan exactamente 3 empleados consiste en determinar cuáles tienen exactamente 3 columnas.

5.1.4. El empleado que trabaja en más sectores

<i>legajo_empleado</i>	K
<i>codigo_sector_donde_trabaja</i>	C ↑

5.1.5. Ranking de los clientes con mayor cantidad de compras

<i>dni_cliente</i>	K
<i>cantidad_compras</i>	++

5.1.6. Cantidad de compras realizadas por clientes de misma edad

<i>edad_cliente</i>	K
<i>cantidad_compras</i>	++

5.2. Sharding

6. Conclusión